

Chapitre I : Introduction à l'analyse de données

Dr. MERGANE

LERSTAD, Université Gaston Berger, Saint-Louis, Sénégal

2022-2023



- 1 Généralités
- 2 Les méthodes factorielles
- 3 Les méthodes non factorielles
- 4 Rappel : Outils statistiques classiques
 - Analyse statistique
 - Analyse descriptive unidimensionnelle
 - Analyse descriptive bidimensionnelle

Généralités

Problème

Lorsqu'on dispose d'un fichier volumineux de données, il est difficile d'appréhender globalement l'information contenue.

Les méthodes statistiques classiques sont insuffisantes.

Généralités

Problème

Lorsqu'on dispose d'un fichier volumineux de données, il est difficile d'appréhender globalement l'information contenue.
Les méthodes statistiques classiques sont insuffisantes.

Solution

Nous avons donc recourt à l'analyse de données (AD) ou « data analysis » en anglais, dont l'objectif principal est de décrire, synthétiser ou de structurer l'information contenue dans la base de données multidimensionnelle.

Généralités

Historique

Les méthodes d'analyse de données sont très anciennes. Mais ses fondements ont été posés dans les années 1930 par Louis Guttman, Chikio Hayashi, etc. et se sont très rapidement développées grâce à l'informatique. Elles sont utilisées dans tous les domaines dès lors que les données se présentent en trop grand nombre pour être appréhender par l'esprit humain. Citons par exemple :

Généralités

Exemples

Généralités

Exemples

- Agriculture : étude des rendements

Généralités

Exemples

- Agriculture : étude des rendements
- Economie : l'étude du PIB et Population d'un ensemble de pays ; pour faire les bilans des entreprises ; étude des valeurs de l'indicateur ;

Généralités

Exemples

- Agriculture : étude des rendements
- Economie : l'étude du PIB et Population d'un ensemble de pays ; pour faire les bilans des entreprises ; étude des valeurs de l'indicateur ;
- Marketing, dans l'étude des valeurs de satisfaction ;

Généralités

Exemples

- Agriculture : étude des rendements
- Economie : l'étude du PIB et Population d'un ensemble de pays ; pour faire les bilans des entreprises ; étude des valeurs de l'indicateur ;
- Marketing, dans l'étude des valeurs de satisfaction ;
- Sociologie : comprendre la vie et le développement de certaines populations ;

Généralités

Exemples

- Agriculture : étude des rendements
- Economie : l'étude du PIB et Population d'un ensemble de pays ; pour faire les bilans des entreprises ; étude des valeurs de l'indicateur ;
- Marketing, dans l'étude des valeurs de satisfaction ;
- Sociologie : comprendre la vie et le développement de certaines populations ;
- Epidémiologie

Généralités

Exemples

- Agriculture : étude des rendements
- Economie : l'étude du PIB et Population d'un ensemble de pays ; pour faire les bilans des entreprises ; étude des valeurs de l'indicateur ;
- Marketing, dans l'étude des valeurs de satisfaction ;
- Sociologie : comprendre la vie et le développement de certaines populations ;
- Epidémiologie
- etc.

Généralités

L'AD est un ensemble de techniques descriptives et qui s'exprime donc sans supposer a priori un modèle probabiliste (pas d'inférence).

Généralités

Grandes familles

En fonction de l'objectif visé, l'AD peut se décomposer en deux grandes familles à savoir les :

- **Méthodes factorielles**
- **Méthodes non factorielles.**

Généralités

Grandes familles

En fonction de l'objectif visé, l'AD peut se décomposer en deux grandes familles à savoir les :

- **Méthodes factorielles**
- **Méthodes non factorielles.**

Remarque

Ces deux méthodes sont plutôt complémentaires que concurrentes, et peuvent avec profit être utilisées conjointement sur un même tableau de données.

Les méthodes factorielles

But et techniques

- L'objectif des méthodes factorielles est de résumer l'information apportée par un ensemble de variables, par un nombre plus restreint de variables nouvelles appelées « facteurs ».
- Elles sont basées sur des outils mathématiques, plus précisément sur l'algèbre matricielle conduisant à l'extraction des valeurs propres, des vecteurs propres et de faire des projections.

Les méthodes factorielles

Selon la nature des variables (quantitatives/qualitatives) étudiées, nous distinguons plusieurs méthodes :

- 👉 **Analyse en Composantes Principales (ACP)**, utilisée pour des variables quantitatives.
- 👉 **Analyse Factorielle des Correspondances (AFC)** dédiée aux tableaux de contingences (deux variables qualitatives).
- 👉 **Analyse Factorielle des Correspondances Multiples (AFCM)**, utilisée lorsqu'on dispose de plusieurs variables qualitatives. Elle généralise l'AFC.
- 👉 **L'analyse Factorielle multiple (AFM)** traite des tableaux dans lesquels les variables, quantitatives ou qualitatives, sont structurées en groupes (exemple d'une enquête dont le questionnaire est structuré en thèmes).
- 👉 **Analyse Factorielle Discriminante (AFD)** permet de décrire un tableau de données constitué de variables quantitatives et d'une variable qualitative en cherchant à afficher distinctement les différentes modalités de la variable qualitative.
- 👉 etc.

Les méthodes non factorielles

Méthodes de classification


Elles sont généralement appelées méthodes de **classification**. Ces dernières sont caractérisées par le choix d'un indice de proximité et d'un algorithme d'agrégation ou de désagrégation qui permettent de regrouper en classes ou catégories qui sont jugées les plus homogènes possibles et cela au regard d'un critère.

Les méthodes non factorielles

Parmi ces méthodes, nous distinguons :

Différentes méthodes de classification

- 👉 **Classification Ascendante Hiérarchique (CAH)**
- 👉 **Classification Descendante Hiérarchique (CDH)**
- 👉 **Méthode des centres mobiles**
- 👉 **etc.**



Plan

- 1 Généralités
- 2 Les méthodes factorielles
- 3 Les méthodes non factorielles
- 4 **Rappel : Outils statistiques classiques**
 - **Analyse statistique**
 - Analyse descriptive unidimensionnelle
 - Analyse descriptive bidimensionnelle


Analyse statistique

☞ L'analyse repose sur l'utilisation des techniques statistiques : Statistique descriptive et/ou Inférentielle.

Analyse statistique

- ☞ L'analyse repose sur l'utilisation des techniques statistiques : Statistique descriptive et/ou Inférentielle.
- ☞ Logiciels statistiques : R, excel, STATA, SPSS, etc.

Structure de la statistique




Variables

👉 **Variable (ou caractère) statistique** : Caractéristique étudiée sur les individus d'une population statistique.

Variables

👉 **Variable (ou caractère) statistique** : Caractéristique étudiée sur les individus d'une population statistique.



Plan

- 1 Généralités
- 2 Les méthodes factorielles
- 3 Les méthodes non factorielles
- 4 **Rappel : Outils statistiques classiques**
 - Analyse statistique
 - **Analyse descriptive unidimensionnelle**
 - Analyse descriptive bidimensionnelle

Analyse statistique simple (unidimensionnelle)

1/3

- **Le tri à plat :**

Première étape de l'analyse statistique.

☞ Consiste à effectuer la répartition des réponses liées à une question.

Analyse statistique simple (unidimensionnelle)

2/3

- Graphes :

☞ Une représentation graphique permet de visualiser les données afin de faire ressortir une partie de l'information.

- **Graphes :**

☞ Une représentation graphique permet de visualiser les données afin de faire ressortir une partie de l'information.

- **Pour une variable qualitative :**

- Graphes :

☞ Une représentation graphique permet de visualiser les données afin de faire ressortir une partie de l'information.

- **Pour une variable qualitative** : Diagramme en barre, Circulaire, etc.

• Graphes :

☞ Une représentation graphique permet de visualiser les données afin de faire ressortir une partie de l'information.

- **Pour une variable qualitative** : Diagramme en barre, Circulaire, etc.
- **Pour une variable quantitative** :

• Graphes :

☞ Une représentation graphique permet de visualiser les données afin de faire ressortir une partie de l'information.

- **Pour une variable qualitative** : Diagramme en barre, Circulaire, etc.
- **Pour une variable quantitative** : Bâtons, Hitogramme, Diagramme cumulatif, etc.

Analyse statistique simple (unidimensionnelle)

3/3

Analyse statistique simple (unidimensionnelle)

3/3

- **Calcul des paramètres statistiques :**

☞ Permet de résumer les données en un seul chiffre.

- Calcul des paramètres statistiques :

☞ Permet de résumer les données en un seul chiffre.

- **Paramètres de position.** Fournissent l'ordre de grandeur des valeurs de la série et la position où se rassemblent ces valeurs.

- Calcul des paramètres statistiques :

☞ Permet de résumer les données en un seul chiffre.

- **Paramètres de position.** Fournissent l'ordre de grandeur des valeurs de la série et la position où se rassemblent ces valeurs.
 - ▶ *Mode, Extrêmes, Moyenne, Quantiles, etc.*

- Calcul des paramètres statistiques :

☞ Permet de résumer les données en un seul chiffre.

- **Paramètres de position.** Fournissent l'ordre de grandeur des valeurs de la série et la position où se rassemblent ces valeurs.
 - ▶ *Mode, Extrêmes, Moyenne, Quantiles, etc.*
- **Paramètres de dispersion.** Quantifient les fluctuations des valeurs autour d'un paramètre de position : précisent la variabilité de la série.

- Calcul des paramètres statistiques :

☞ Permet de résumer les données en un seul chiffre.

- **Paramètres de position.** Fournissent l'ordre de grandeur des valeurs de la série et la position où se rassemblent ces valeurs.
 - ▶ *Mode, Extrêmes, Moyenne, Quantiles, etc.*
- **Paramètres de dispersion.** Quantifient les fluctuations des valeurs autour d'un paramètre de position : précisent la variabilité de la série.
 - ▶ *Etendue, Ecart-Interquantiles, Variance, Ecart-type etc.*

• Calcul des paramètres statistiques :

☞ Permet de résumer les données en un seul chiffre.

- **Paramètres de position.** Fournissent l'ordre de grandeur des valeurs de la série et la position où se rassemblent ces valeurs.
 - ▶ *Mode, Extrêmes, Moyenne, Quantiles, etc.*
- **Paramètres de dispersion.** Quantifient les fluctuations des valeurs autour d'un paramètre de position : précisent la variabilité de la série.
 - ▶ *Etendue, Ecart-Interquantiles, Variance, Ecart-type etc.*
- **Paramètres de concentration.** Etudient la densité des données autour de la valeur centrale afin de se prononcer sur l'égalité d'une distribution.

• Calcul des paramètres statistiques :

☞ Permet de résumer les données en un seul chiffre.

- **Paramètres de position.** Fournissent l'ordre de grandeur des valeurs de la série et la position où se rassemblent ces valeurs.
 - ▶ *Mode, Extrêmes, Moyenne, Quantiles, etc.*
- **Paramètres de dispersion.** Quantifient les fluctuations des valeurs autour d'un paramètre de position : précisent la variabilité de la série.
 - ▶ *Etendue, Ecart-Interquantiles, Variance, Ecart-type etc.*
- **Paramètres de concentration.** Etudient la densité des données autour de la valeur centrale afin de se prononcer sur l'égalité d'une distribution.
 - ▶ *Coefficient de concentration , Indice de Gini, etc.*

• Calcul des paramètres statistiques :

☞ Permet de résumer les données en un seul chiffre.

- **Paramètres de position.** Fournissent l'ordre de grandeur des valeurs de la série et la position où se rassemblent ces valeurs.
 - ▶ *Mode, Extrêmes, Moyenne, Quantiles, etc.*
- **Paramètres de dispersion.** Quantifient les fluctuations des valeurs autour d'un paramètre de position : précisent la variabilité de la série.
 - ▶ *Etendue, Ecart-Interquantiles, Variance, Ecart-type etc.*
- **Paramètres de concentration.** Etudient la densité des données autour de la valeur centrale afin de se prononcer sur l'égalité d'une distribution.
 - ▶ *Coefficient de concentration , Indice de Gini, etc.*
- **Paramètres de forme.** Etudient l'asymétrie (Skewness) et l'aplatissement (Kurtosis) d'une distribution.

• Calcul des paramètres statistiques :

☞ Permet de résumer les données en un seul chiffre.

- **Paramètres de position.** Fournissent l'ordre de grandeur des valeurs de la série et la position où se rassemblent ces valeurs.
 - ▶ *Mode, Extrêmes, Moyenne, Quantiles, etc.*
- **Paramètres de dispersion.** Quantifient les fluctuations des valeurs autour d'un paramètre de position : précisent la variabilité de la série.
 - ▶ *Etendue, Ecart-Interquantiles, Variance, Ecart-type etc.*
- **Paramètres de concentration.** Etudient la densité des données autour de la valeur centrale afin de se prononcer sur l'égalité d'une distribution.
 - ▶ *Coefficient de concentration, Indice de Gini, etc.*
- **Paramètres de forme.** Etudient l'asymétrie (Skewness) et l'aplatissement (Kurtosis) d'une distribution.
 - ▶ *Skewness : Coefficient de Yule, de Fisher, etc.*
 - ▶ *Kurtosis : Coefficient de Pearson*

Plan

- 1 Généralités
- 2 Les méthodes factorielles
- 3 Les méthodes non factorielles
- 4 **Rappel : Outils statistiques classiques**
 - Analyse statistique
 - Analyse descriptive unidimensionnelle
 - **Analyse descriptive bidimensionnelle**

Analyse statistique bidimensionnelle

Analyse statistique bidimensionnelle

- **Le tri croisé :**

☞ Consiste à mettre en relation les réponses de deux questions différentes :
Tableau à double entrée (de contingence).

Analyse statistique bidimensionnelle

- **Le tri croisé :**

☞ Consiste à mettre en relation les réponses de deux questions différentes : Tableau à double entrée (de contingence).

- **Graphes**

Nuage de points ; Graphe en mosaïques ; Diagramme en barre empilé ; etc.

Analyse statistique bidimensionnelle

• Le tri croisé :

☞ Consiste à mettre en relation les réponses de deux questions différentes : Tableau à double entrée (de contingence).

• Graphes

Nuage de points ; Graphe en mosaïques ; Diagramme en barre empilé ; etc.

• Mesure de dépendance

Covariance, Coefficient de corrélation, Indices de dépendance, etc.

Chapitre II : Analyse en Composantes Principales

Dr. MERGANE

LERSTAD, Université Gaston Berger, Saint-Louis, Sénégal

2022-2023



1 Introduction

2 Les données

- Présentation des données
- Les étapes d'une ACP
 - Choix de la matrice
 - Diagonalisation

3 Aides à l'interprétation

- Choix du nombre d'axes à retenir
- Qualité de l'analyse
 - Qualité globale de la représentation
 - Qualité locale de la représentation

4 Application

Généralités

Introduction

L'Analyse en Composantes Principales ACP (Principal Component Analysis) est la méthode d'analyse factorielle la plus ancienne (1901, Pearson). Elle poursuit les deux objectifs suivants : visualiser les données et réduire la dimension effective des données.

Elle permet donc de condenser l'information contenue dans un tableau de données de dimension importante dont toutes les variables sont quantitatives, de manière à retirer les relations caractéristiques (proximités entre individus et liens entre variables) en minimisant la perte d'information.

Généralités

Introduction

Géométriquement, si le tableau contient p variables (colonnes) observées sur n individus (lignes), l'objectif d'une ACP est de trouver un sous espace de dimension q inférieure à la dimension du tableau de données sur lequel on projette le nuage de points sous la condition :

- la projection doit être la plus fidèle possible à la réalité c'est-à-dire la déformation du nuage de points doit être moindre.

Autrement dit, on cherche la projection qui conserve le plus de variabilité. Le premier axe trouvé est issu d'une combinaison linéaire des variables initiales, tel que la variance du nuage autour de cet axe soit maximale porte le nom de **composante principale**. Puis, on réitère ce processus dans des directions orthogonales pour déterminer les composantes principales suivantes.

Généralités

Introduction

Géométriquement, si le tableau contient p variables (colonnes) observées sur n individus (lignes), l'objectif d'une ACP est de trouver un sous espace de dimension q inférieure à la dimension du tableau de données sur lequel on projette le nuage de points sous la condition :

- la projection doit être la plus fidèle possible à la réalité c'est-à-dire la déformation du nuage de points doit être moindre.

Autrement dit, on cherche la projection qui conserve le plus de variabilité. Le premier axe trouvé est issu d'une combinaison linéaire des variables initiales, tel que la variance du nuage autour de cet axe soit maximale porte le nom de **composante principale**. Puis, on réitère ce processus dans des directions orthogonales pour déterminer les composantes principales suivantes.

Remarque

L'ACP permet de conserver au mieux la structure de corrélation entre les variables initiales.

Plan

- 1 Introduction
- 2 Les données
 - **Présentation des données**
 - Les étapes d'une ACP
 - Choix de la matrice
 - Diagonalisation
- 3 Aides à l'interprétation
 - Choix du nombre d'axes à retenir
 - Qualité de l'analyse
 - Qualité globale de la représentation
 - Qualité locale de la représentation
- 4 Application

Données initiales

La base de données de n lignes représentées par les individus et de p colonnes par les variables X_i

Individu i	Variable X_1	Variable X_2	$\dots$	Variable X_p
1	x_{11}	x_{12}	$\dots$	x_{1p}
2	x_{21}	x_{22}	$\dots$	x_{2p}
3	x_{31}	x_{32}	$\dots$	x_{3p}
$\vdots$	$\vdots$	$\vdots$	$\dots$	$\vdots$
i	x_{i1}	x_{i2}	$\dots$	x_{ip}
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
n	x_{n1}	x_{n2}	$\dots$	x_{np}

Tab.: Tableau de données brutes

Matrice d'information

$$X = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ x_{31} & x_{32} & \cdots & x_{3p} \\ \vdots & \vdots & \cdots & \vdots \\ x_{i1} & x_{i2} & \cdots & x_{ip} \\ \vdots & \vdots & \vdots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{pmatrix}$$

On définit par $\mathbb{1}_n$ la matrice colonne de n lignes dont tous les éléments sont égaux à l'unité et par $\mathbb{I}_n$ la matrice identité d'ordre n .

$$\mathbb{1}_n = \begin{pmatrix} 1 \\ 1 \\ 1 \\ \vdots \\ 1 \end{pmatrix}, \quad \mathbb{I}_n = \begin{pmatrix} 1 & 0 & \cdots & 0 \\ 0 & 1 & \cdots & 0 \\ 0 & 0 & \cdots & 0 \\ \vdots & \vdots & \cdots & \vdots \\ 0 & 0 & \cdots & 1 \end{pmatrix}$$

Matrice des poids

A chaque individu i , on lui associe un poids p_i vérifiant :

$$p_1 + p_2 + \cdots + p_n = 1.$$

La matrice des poids est une matrice diagonale de taille n

$$D_p = \begin{pmatrix} p_1 & 0 & \cdots & 0 \\ 0 & p_2 & \cdots & 0 \\ 0 & 0 & \cdots & 0 \\ \vdots & \vdots & \cdots & \vdots \\ 0 & 0 & \cdots & p_n \end{pmatrix}$$

Matrice des poids

Dans le cas où :

$$p_1 = p_2 = \cdots = p_n = \frac{1}{n},$$

on parle de cas uniforme et on dit que tous les individus ont la même importance.

$$D_p = \begin{pmatrix} 1/n & 0 & \cdots & 0 \\ 0 & 1/n & \cdots & 0 \\ 0 & 0 & \cdots & 0 \\ \vdots & \vdots & \cdots & \vdots \\ 0 & 0 & \cdots & 1/n \end{pmatrix}$$

Point moyen = centre de gravité

$$G^t = (\overline{X}_1, \overline{X}_2, \dots, \overline{X}_p) \quad \text{où} \quad \overline{X}_j = \frac{1}{n} \sum_{i=1}^n x_{ij}$$

Alors

$$G = X^t D_p \mathbb{1}_n.$$

En effet :

$$D_p \mathbb{1}_n = \begin{pmatrix} 1/n & 0 & \cdots & 0 \\ 0 & 1/n & \cdots & 0 \\ 0 & 0 & \cdots & 0 \\ \vdots & \vdots & \cdots & \vdots \\ 0 & 0 & \cdots & 1/n \end{pmatrix} \begin{pmatrix} 1 \\ 1 \\ 1 \\ \vdots \\ 1 \end{pmatrix} = \begin{pmatrix} 1/n \\ 1/n \\ 1/n \\ \vdots \\ 1/n \end{pmatrix}$$

$$X^t (D_p \mathbb{1}_n) = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ x_{31} & x_{32} & \cdots & x_{3p} \\ \vdots & \vdots & \cdots & \vdots \\ x_{i1} & x_{i2} & \cdots & x_{ip} \\ \vdots & \vdots & \vdots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{pmatrix}^t \begin{pmatrix} 1/n \\ 1/n \\ 1/n \\ \vdots \\ 1/n \end{pmatrix}$$

Donc,

$$X^t(D_p \mathbb{1}_n) = \begin{pmatrix} \frac{1}{n} \sum_{i=1}^n x_{i1} \\ \frac{1}{n} \sum_{i=1}^n x_{i2} \\ \vdots \\ \frac{1}{n} \sum_{i=1}^n x_{ip} \end{pmatrix} = \begin{pmatrix} \bar{X}_1 \\ \bar{X}_2 \\ \vdots \\ \bar{X}_p \end{pmatrix}$$

Tableau centré

On retranche à chaque valeur prise par X_j sa moyenne $\bar{X}_j$ i.e. $y_{ij} = x_{ij} - \bar{X}_j$.

$$Y = X - \mathbf{1}_n G^t$$

Matrice de variance-covariance

$$V = \begin{pmatrix} \sigma_1^2 & \sigma_{12} & \cdots & \sigma_{1p} \\ \sigma_{12} & \sigma_2^2 & \cdots & \sigma_{2p} \\ \vdots & \vdots & \cdots & \vdots \\ \sigma_{1p} & \sigma_{2p} & \cdots & \sigma_p^2 \end{pmatrix},$$

avec

$$\sigma_{ij} = \text{cov}(X_i, X_j) \text{ et } \sigma_j^2 = \text{cov}(X_j, X_j).$$

$$V = X^t D_p X - G G^t = Y^t D_p Y, p = 1/n.$$

Matrice des données centrées et réduites

$$z_{ij} = \frac{x_{ij} - \bar{X}_j}{\sigma_j}$$

$$Z = YD_{1/\sigma} \text{ où } D_{1/\sigma} = \begin{pmatrix} 1/\sigma_1 & 0 & \cdots & 0 \\ 0 & 1/\sigma_2 & \cdots & 0 \\ 0 & 0 & \cdots & 0 \\ \vdots & \vdots & \cdots & \vdots \\ 0 & 0 & \cdots & 1/\sigma_p \end{pmatrix}$$

Matrice de corrélations

$$r_{ij} = \frac{\text{cov}(X_i, X_j)}{\sigma_i \sigma_j},$$

$$R = \begin{pmatrix} 1 & r_{12} & \cdots & r_{1p} \\ r_{12} & 1 & \cdots & r_{2p} \\ \vdots & \vdots & \cdots & \vdots \\ r_{1p} & r_{2p} & \cdots & 1 \end{pmatrix}$$

Remarque

Cette matrice fournit des éléments de description des associations entre variables. Elle nous permet d'avoir une première idée sur l'intensité de la liaison linéaire entre les variables. Mais l'ACP nous permettra d'obtenir une synthèse de ces liaisons.

Plan

- 1 Introduction
- 2 Les données
 - Présentation des données
 - **Les étapes d'une ACP**
 - **Choix de la matrice**
 - Diagonalisation
- 3 Aides à l'interprétation
 - Choix du nombre d'axes à retenir
 - Qualité de l'analyse
 - Qualité globale de la représentation
 - Qualité locale de la représentation
- 4 Application

Choix de la matrice

Pour faire une ACP, on centre d'abord les données et on obtient la matrice Y .
Géométriquement, ceci revient à faire un changement d'origine.

Si l'analyse porte sur la matrice Y on parle **d'ACP non normée**.

Choix de la matrice

Pour faire une ACP, on centre d'abord les données et on obtient la matrice Y . Géométriquement, ceci revient à faire un changement d'origine.

Si l'analyse porte sur la matrice Y on parle **d'ACP non normée**.

Par contre du fait de l'hétérogénéité des variables initiales et de leurs unités, on normalise pour obtenir la matrice Z . Et si l'étude se poursuit avec Z , on parle **d'ACP normée**.

Cette dernière permet donc d'éviter de privilégier les variables fortement dispersées.

Choix de la matrice

Pour faire une ACP, on centre d'abord les données et on obtient la matrice Y . Géométriquement, ceci revient à faire un changement d'origine.

Si l'analyse porte sur la matrice Y on parle **d'ACP non normée**.

Par contre du fait de l'hétérogénéité des variables initiales et de leurs unités, on normalise pour obtenir la matrice Z . Et si l'étude se poursuit avec Z , on parle **d'ACP normée**.

Cette dernière permet donc d'éviter de privilégier les variables fortement dispersées.

On calcule ensuite la matrice de variance covariance de la matrice considérée (Y : ACP non normée ou Z : ACP normée).

Nous travaillons dans ce cours avec Z .

Choix de la matrice

Pour faire une ACP, on centre d'abord les données et on obtient la matrice Y . Géométriquement, ceci revient à faire un changement d'origine.

Si l'analyse porte sur la matrice Y on parle **d'ACP non normée**.

Par contre du fait de l'hétérogénéité des variables initiales et de leurs unités, on normalise pour obtenir la matrice Z . Et si l'étude se poursuit avec Z , on parle **d'ACP normée**.

Cette dernière permet donc d'éviter de privilégier les variables fortement dispersées.

On calcule ensuite la matrice de variance covariance de la matrice considérée (Y : ACP non normée ou Z : ACP normée).

Nous travaillons dans ce cours avec Z .

Remarque

Dans le cas d'une ACP normée, la matrice de variance covariance de Z coïncide avec la matrice de corrélations R .

Diagonalisation

Cette deuxième étape consiste à trouver les valeurs propres de la matrice de corrélation R , puis d'en déduire les vecteurs propres associés.

Les valeurs propres sont obtenues en résolvant :

$$\det(R - \lambda \mathbb{I}_p) = 0$$

et les λ_i ($i = 1, 2, \dots, p$) solutions vérifient $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p$.

Diagonalisation : les facteurs principaux

- Les p vecteurs propres orthonormés $(U_1, U_2, \dots, U_p)$ de R sont appelés **facteurs principaux**. Ils vérifient

$$RU_k = \lambda_k U_k, \text{ avec } \langle U_k, U_l \rangle = 1 \text{ si } k = l \text{ et } 0 \text{ sinon.}$$

Notons par U la matrice dont les colonnes sont les U_k .

$$U = \begin{pmatrix} u_{11} & u_{12} & \cdots & u_{1p} \\ u_{21} & u_{22} & \cdots & u_{2p} \\ u_{31} & u_{32} & \cdots & u_{3p} \\ \vdots & \vdots & \cdots & \vdots \\ u_{p1} & u_{p2} & \cdots & u_{pp} \end{pmatrix}$$

Diagonalisation : les composantes principales

- La matrice des données dans la base des vecteurs propres $(U_1, U_2, \dots, U_p)$ est :

$$C = ZU.$$

Les composantes principales sont données par :

$$C_k = ZU_k \text{ où } c_{ij} = \sum_{k=1}^p z_{ik} u_{kj}, j = 1, 2, \dots, n.$$

Remarque

- $\bar{C}_k = 0$
- $\text{var}(C_k) = \lambda_k$

Plan

- 1 Introduction
- 2 Les données
 - Présentation des données
 - Les étapes d'une ACP
 - Choix de la matrice
 - Diagonalisation
- 3 Aides à l'interprétation
 - Choix du nombre d'axes à retenir
 - Qualité de l'analyse
 - Qualité globale de la représentation
 - Qualité locale de la représentation
- 4 Application

Choix du nombre d'axes à retenir

- 👉 **Règle de Kaiser** : le nombre d'axes à retenir est le nombre de valeurs propres supérieurs ou égaux à 1
- 👉 **Règle de l'inertie minimale** : on sélectionne les premiers axes afin d'atteindre un pourcentage donné d'inertie minimale (Exemple : 80%. Si on a 80% de l'information c'est bon)
- 👉 **Règle du coude** : on retient les axes avant le coude (décrochage) dans le diagramme des valeurs propres
- 👉 **Règle du bon sens** : on retient les axes interprétables

Plan

- 1 Introduction
- 2 Les données
 - Présentation des données
 - Les étapes d'une ACP
 - Choix de la matrice
 - Diagonalisation
- 3 Aides à l'interprétation
 - Choix du nombre d'axes à retenir
 - Qualité de l'analyse
 - Qualité globale de la représentation
 - Qualité locale de la représentation
- 4 Application

Qualité globale de la représentation

 **Inertie totale** : c'est l'information totale à résumer

$$I_g = \text{tr}(R) = \lambda_1 + \lambda_2 + \cdots + \lambda_p.$$

Remarque

Dans le cas d'une ACP :

- Normée, $I_g = p$
- Non normée, $I_g = \sigma_1^2 + \sigma_2^2 + \cdots + \sigma_p^2$

Qualité globale de la représentation

 **Contribution de l'axe k :** qualité de l'information résumée par l'axe factoriel k . C'est la part de l'information expliquée par la $k^{\text{ième}}$ composante.

$$q_k = \frac{\lambda_k}{I_g} (\times 100)$$

Qualité globale de la représentation

 **Qualité de l'information résumée par les k axes factoriels** : la part de l'information expliquée par les k composantes principales :

$$Q_k = \frac{\lambda_1 + \lambda_2 + \dots + \lambda_k}{I_g} (\times 100)$$

 Elle mesure la précision et la pertinence de l'ACP.

 Plus cette quantité est proche de 100%, plus le nuage de points initial est concentré autour de $\langle U_1, U_2, \dots, U_q \rangle$, et plus fidèle est son image sur ce sous espace.

Qualité locale de la représentation : Pour les variables

Les variables sont projetées orthogonalement dans le plan défini par deux composantes. Par exemple, (C_1, C_2) .

Chaque variable X_i , a pour coordonnée sur la composante C_j

$$\text{cor}(X_i, C_j) = u_{ij} \sqrt{\lambda_j}$$

Par exemple, sur le premier plan factoriel, X_i est représentée par un point d'abscisse $u_{i1} \sqrt{\lambda_1}$ et d'ordonnée $u_{i2} \sqrt{\lambda_2}$.

Le graphe ainsi obtenu porte le nom de **cercle de corrélations**. Il permet de visualiser comment les variables sont corrélées (positement ou négativement) entre elles et avec les composantes principales.

Qualité locale de la représentation : Pour les variables

Lecture du cercle de corrélations

- Une variable non corrélée à la composante principale est mal représentée : sa projection est proche du centre.
On interprète que les variables proches du bord du cercle.
- Pour les variables bien représentées, l'analyse de la liaison se fait comme suit :
 - les vecteurs qui ont même direction et même sens sont corrélés positivement ;
 - Les vecteurs qui ont même direction et de sens opposés sont corrélés négativement ;
 - Les vecteurs perpendiculaires indiquent une absence de corrélation.

Qualité locale de la représentation : Pour les individus

La meilleure représentation graphique est donnée par la projection du nuage sur l'espace principal engendré par les q premiers axes principaux $U_1, U_2, \dots, U_q$ et que la coordonnée d'un individu i sur l'axe F_k est c_{ik} .

Les points les plus intéressants (parlants) sont généralement ceux qui sont assez proches d'un axe et loin de l'origine : leur « vraie » distance de l'origine est bien représentée sur le plan factoriel considéré. Ils sont bien corrélés avec cet axe. On les appelle les points explicatifs pour l'axe.

Ainsi les axes s'interprètent de la même manière que les axes des graphes des variables.

Qualité locale de la représentation : Pour les individus

La qualité de la représentation d'un individu est donnée par le cosinus carré de l'angle qu'il forme avec sa projection.

- $qlt(Ind. i, F_k) = \frac{(c_{ik})^2}{\sum_{k=1}^p (c_{ik})^2}$
- $qlt(Ind. i, (F_1, F_2)) = \frac{(c_{i1})^2 + (c_{i2})^2}{\sum_{k=1}^p (c_{ik})^2}$

➡ Plus le $\cos^2$ est proche de un, meilleur est la représentation.

Qualité locale de la représentation : Pour les individus

Contribution

La contribution d'individu à la construction d'un axe permet de détecter les individus aberrants (outliers) : les individus ayant une influence sur la construction d'un axe. Ces individus peuvent déterminer à eux seuls l'orientation des axes.

$$ctr(Ind.i, F_k) = \frac{(c_{ik})^2}{n \lambda_k}$$

Exemple

Exemple

	V1	V2	V3
Ind1	12.04	23.7	5.9
Ind2	17.18	15.5	-1.8
Ind3	11.83	13.1	2.8
Ind4	6.23	13.5	-2.4
Ind5	16.99	21.1	7.2
Ind6	3.87	20.3	-0.9

