

Chapitre I : Introduction à l'analyse de données

Dr. MERGANE

LERSTAD, Université Gaston Berger, Saint-Louis, Sénégal

2022-2023



- 1 Généralités
- 2 Les méthodes factorielles
- 3 Les méthodes non factorielles
- 4 Rappel : Outils statistiques classiques
 - Analyse statistique
 - Analyse descriptive unidimensionnelle
 - Analyse descriptive bidimensionnelle

Généralités

Problème

Lorsqu'on dispose d'un fichier volumineux de données, il est difficile d'appréhender globalement l'information contenue.

Les méthodes statistiques classiques sont insuffisantes.

Généralités

Problème

Lorsqu'on dispose d'un fichier volumineux de données, il est difficile d'appréhender globalement l'information contenue.
Les méthodes statistiques classiques sont insuffisantes.

Solution

Nous avons donc recourt à l'analyse de données (AD) ou « data analysis » en anglais, dont l'objectif principal est de décrire, synthétiser ou de structurer l'information contenue dans la base de données multidimensionnelle.

Généralités

Historique

Les méthodes d'analyse de données sont très anciennes. Mais ses fondements ont été posés dans les années 1930 par Louis Guttman, Chikio Hayashi, etc. et se sont très rapidement développées grâce à l'informatique. Elles sont utilisées dans tous les domaines dès lors que les données se présentent en trop grand nombre pour être appréhender par l'esprit humain. Citons par exemple :

Généralités

Exemples

Généralités

Exemples

- Agriculture : étude des rendements

Généralités

Exemples

- Agriculture : étude des rendements
- Economie : l'étude du PIB et Population d'un ensemble de pays ; pour faire les bilans des entreprises ; étude des valeurs de l'indicateur ;

Généralités

Exemples

- Agriculture : étude des rendements
- Economie : l'étude du PIB et Population d'un ensemble de pays ; pour faire les bilans des entreprises ; étude des valeurs de l'indicateur ;
- Marketing, dans l'étude des valeurs de satisfaction ;

Généralités

Exemples

- Agriculture : étude des rendements
- Economie : l'étude du PIB et Population d'un ensemble de pays ; pour faire les bilans des entreprises ; étude des valeurs de l'indicateur ;
- Marketing, dans l'étude des valeurs de satisfaction ;
- Sociologie : comprendre la vie et le développement de certaines populations ;

Généralités

Exemples

- Agriculture : étude des rendements
- Economie : l'étude du PIB et Population d'un ensemble de pays ; pour faire les bilans des entreprises ; étude des valeurs de l'indicateur ;
- Marketing, dans l'étude des valeurs de satisfaction ;
- Sociologie : comprendre la vie et le développement de certaines populations ;
- Epidémiologie

Généralités

Exemples

- Agriculture : étude des rendements
- Economie : l'étude du PIB et Population d'un ensemble de pays ; pour faire les bilans des entreprises ; étude des valeurs de l'indicateur ;
- Marketing, dans l'étude des valeurs de satisfaction ;
- Sociologie : comprendre la vie et le développement de certaines populations ;
- Epidémiologie
- etc.

Généralités

L'AD est un ensemble de techniques descriptives et qui s'exprime donc sans supposer a priori un modèle probabiliste (pas d'inférence).

Généralités

Grandes familles

En fonction de l'objectif visé, l'AD peut se décomposer en deux grandes familles à savoir les :

- **Méthodes factorielles**
- **Méthodes non factorielles.**

Généralités

Grandes familles

En fonction de l'objectif visé, l'AD peut se décomposer en deux grandes familles à savoir les :

- **Méthodes factorielles**
- **Méthodes non factorielles.**

Remarque

Ces deux méthodes sont plutôt complémentaires que concurrentes, et peuvent avec profit être utilisées conjointement sur un même tableau de données.

Les méthodes factorielles

But et techniques

- L'objectif des méthodes factorielles est de résumer l'information apportée par un ensemble de variables, par un nombre plus restreint de variables nouvelles appelées « facteurs ».
- Elles sont basées sur des outils mathématiques, plus précisément sur l'algèbre matricielle conduisant à l'extraction des valeurs propres, des vecteurs propres et de faire des projections.

Les méthodes factorielles

Selon la nature des variables (quantitatives/qualitatives) étudiées, nous distinguons plusieurs méthodes :

- 👉 **Analyse en Composantes Principales (ACP)**, utilisée pour des variables quantitatives.
- 👉 **Analyse Factorielle des Correspondances (AFC)** dédiée aux tableaux de contingences (deux variables qualitatives).
- 👉 **Analyse Factorielle des Correspondances Multiples (AFCM)**, utilisée lorsqu'on dispose de plusieurs variables qualitatives. Elle généralise l'AFC.
- 👉 **L'analyse Factorielle multiple (AFM)** traite des tableaux dans lesquels les variables, quantitatives ou qualitatives, sont structurées en groupes (exemple d'une enquête dont le questionnaire est structuré en thèmes).
- 👉 **Analyse Factorielle Discriminante (AFD)** permet de décrire un tableau de données constitué de variables quantitatives et d'une variable qualitative en cherchant à afficher distinctement les différentes modalités de la variable qualitative.
- 👉 etc.

Les méthodes non factorielles

Méthodes de classification


Elles sont généralement appelées méthodes de **classification**. Ces dernières sont caractérisées par le choix d'un indice de proximité et d'un algorithme d'agrégation ou de désagrégation qui permettent de regrouper en classes ou catégories qui sont jugées les plus homogènes possibles et cela au regard d'un critère.

Les méthodes non factorielles

Parmi ces méthodes, nous distinguons :

Différentes méthodes de classification

- 👉 **Classification Ascendante Hiérarchique (CAH)**
- 👉 **Classification Descendante Hiérarchique (CDH)**
- 👉 **Méthode des centres mobiles**
- 👉 **etc.**



Plan

- 1 Généralités
- 2 Les méthodes factorielles
- 3 Les méthodes non factorielles
- 4 **Rappel : Outils statistiques classiques**
 - **Analyse statistique**
 - Analyse descriptive unidimensionnelle
 - Analyse descriptive bidimensionnelle


Analyse statistique

☞ L'analyse repose sur l'utilisation des techniques statistiques : Statistique descriptive et/ou Inférentielle.

Analyse statistique

- ☞ L'analyse repose sur l'utilisation des techniques statistiques : Statistique descriptive et/ou Inférentielle.
- ☞ Logiciels statistiques : R, excel, STATA, SPSS, etc.

Structure de la statistique




Variables

👉 **Variable (ou caractère) statistique** : Caractéristique étudiée sur les individus d'une population statistique.

Variables

👉 **Variable (ou caractère) statistique** : Caractéristique étudiée sur les individus d'une population statistique.



Plan

- 1 Généralités
- 2 Les méthodes factorielles
- 3 Les méthodes non factorielles
- 4 **Rappel : Outils statistiques classiques**
 - Analyse statistique
 - **Analyse descriptive unidimensionnelle**
 - Analyse descriptive bidimensionnelle

Analyse statistique simple (unidimensionnelle)

1/3

- **Le tri à plat :**

Première étape de l'analyse statistique.

☞ Consiste à effectuer la répartition des réponses liées à une question.

Analyse statistique simple (unidimensionnelle)

2/3

- Graphes :

☞ Une représentation graphique permet de visualiser les données afin de faire ressortir une partie de l'information.

- **Graphes :**

☞ Une représentation graphique permet de visualiser les données afin de faire ressortir une partie de l'information.

- **Pour une variable qualitative :**

- Graphes :

☞ Une représentation graphique permet de visualiser les données afin de faire ressortir une partie de l'information.

- **Pour une variable qualitative** : Diagramme en barre, Circulaire, etc.

• Graphes :

☞ Une représentation graphique permet de visualiser les données afin de faire ressortir une partie de l'information.

- **Pour une variable qualitative** : Diagramme en barre, Circulaire, etc.
- **Pour une variable quantitative** :

• Graphes :

☞ Une représentation graphique permet de visualiser les données afin de faire ressortir une partie de l'information.

- **Pour une variable qualitative** : Diagramme en barre, Circulaire, etc.
- **Pour une variable quantitative** : Bâtons, Hitogramme, Diagramme cumulatif, etc.

Analyse statistique simple (unidimensionnelle)

3/3

Analyse statistique simple (unidimensionnelle)

3/3

- **Calcul des paramètres statistiques :**

☞ Permet de résumer les données en un seul chiffre.

- Calcul des paramètres statistiques :

☞ Permet de résumer les données en un seul chiffre.

- **Paramètres de position.** Fournissent l'ordre de grandeur des valeurs de la série et la position où se rassemblent ces valeurs.

- Calcul des paramètres statistiques :

☞ Permet de résumer les données en un seul chiffre.

- **Paramètres de position.** Fournissent l'ordre de grandeur des valeurs de la série et la position où se rassemblent ces valeurs.
 - ▶ *Mode, Extrêmes, Moyenne, Quantiles, etc.*

- Calcul des paramètres statistiques :

☞ Permet de résumer les données en un seul chiffre.

- **Paramètres de position.** Fournissent l'ordre de grandeur des valeurs de la série et la position où se rassemblent ces valeurs.
 - ▶ *Mode, Extrêmes, Moyenne, Quantiles, etc.*
- **Paramètres de dispersion.** Quantifient les fluctuations des valeurs autour d'un paramètre de position : précisent la variabilité de la série.

- Calcul des paramètres statistiques :

☞ Permet de résumer les données en un seul chiffre.

- **Paramètres de position.** Fournissent l'ordre de grandeur des valeurs de la série et la position où se rassemblent ces valeurs.
 - ▶ *Mode, Extrêmes, Moyenne, Quantiles, etc.*
- **Paramètres de dispersion.** Quantifient les fluctuations des valeurs autour d'un paramètre de position : précisent la variabilité de la série.
 - ▶ *Etendue, Ecart-Interquantiles, Variance, Ecart-type etc.*

• Calcul des paramètres statistiques :

☞ Permet de résumer les données en un seul chiffre.

- **Paramètres de position.** Fournissent l'ordre de grandeur des valeurs de la série et la position où se rassemblent ces valeurs.
 - ▶ *Mode, Extrêmes, Moyenne, Quantiles, etc.*
- **Paramètres de dispersion.** Quantifient les fluctuations des valeurs autour d'un paramètre de position : précisent la variabilité de la série.
 - ▶ *Etendue, Ecart-Interquantiles, Variance, Ecart-type etc.*
- **Paramètres de concentration.** Etudient la densité des données autour de la valeur centrale afin de se prononcer sur l'égalité d'une distribution.

• Calcul des paramètres statistiques :

☞ Permet de résumer les données en un seul chiffre.

- **Paramètres de position.** Fournissent l'ordre de grandeur des valeurs de la série et la position où se rassemblent ces valeurs.
 - ▶ *Mode, Extrêmes, Moyenne, Quantiles, etc.*
- **Paramètres de dispersion.** Quantifient les fluctuations des valeurs autour d'un paramètre de position : précisent la variabilité de la série.
 - ▶ *Etendue, Ecart-Interquantiles, Variance, Ecart-type etc.*
- **Paramètres de concentration.** Etudient la densité des données autour de la valeur centrale afin de se prononcer sur l'égalité d'une distribution.
 - ▶ *Coefficient de concentration , Indice de Gini, etc.*

• Calcul des paramètres statistiques :

☞ Permet de résumer les données en un seul chiffre.

- **Paramètres de position.** Fournissent l'ordre de grandeur des valeurs de la série et la position où se rassemblent ces valeurs.
 - ▶ *Mode, Extrêmes, Moyenne, Quantiles, etc.*
- **Paramètres de dispersion.** Quantifient les fluctuations des valeurs autour d'un paramètre de position : précisent la variabilité de la série.
 - ▶ *Etendue, Ecart-Interquantiles, Variance, Ecart-type etc.*
- **Paramètres de concentration.** Etudient la densité des données autour de la valeur centrale afin de se prononcer sur l'égalité d'une distribution.
 - ▶ *Coefficient de concentration , Indice de Gini, etc.*
- **Paramètres de forme.** Etudient l'asymétrie (Skewness) et l'aplatissement (Kurtosis) d'une distribution.

• Calcul des paramètres statistiques :

☞ Permet de résumer les données en un seul chiffre.

- **Paramètres de position.** Fournissent l'ordre de grandeur des valeurs de la série et la position où se rassemblent ces valeurs.
 - ▶ *Mode, Extrêmes, Moyenne, Quantiles, etc.*
- **Paramètres de dispersion.** Quantifient les fluctuations des valeurs autour d'un paramètre de position : précisent la variabilité de la série.
 - ▶ *Etendue, Ecart-Interquantiles, Variance, Ecart-type etc.*
- **Paramètres de concentration.** Etudient la densité des données autour de la valeur centrale afin de se prononcer sur l'égalité d'une distribution.
 - ▶ *Coefficient de concentration, Indice de Gini, etc.*
- **Paramètres de forme.** Etudient l'asymétrie (Skewness) et l'aplatissement (Kurtosis) d'une distribution.
 - ▶ *Skewness : Coefficient de Yule, de Fisher, etc.*
 - ▶ *Kurtosis : Coefficient de Pearson*

Plan

- 1 Généralités
- 2 Les méthodes factorielles
- 3 Les méthodes non factorielles
- 4 **Rappel : Outils statistiques classiques**
 - Analyse statistique
 - Analyse descriptive unidimensionnelle
 - **Analyse descriptive bidimensionnelle**

Analyse statistique bidimensionnelle

Analyse statistique bidimensionnelle

- **Le tri croisé :**

☞ Consiste à mettre en relation les réponses de deux questions différentes :
Tableau à double entrée (de contingence).

Analyse statistique bidimensionnelle

- **Le tri croisé :**

☞ Consiste à mettre en relation les réponses de deux questions différentes : Tableau à double entrée (de contingence).

- **Graphes**

Nuage de points ; Graphe en mosaïques ; Diagramme en barre empilé ; etc.

Analyse statistique bidimensionnelle

• Le tri croisé :

☞ Consiste à mettre en relation les réponses de deux questions différentes : Tableau à double entrée (de contingence).

• Graphes

Nuage de points ; Graphe en mosaïques ; Diagramme en barre empilé ; etc.

• Mesure de dépendance

Covariance, Coefficient de corrélation, Indices de dépendance, etc.

