

Chapitre IV : Classification Ascendante Hiérarchique

Dr. MERGANE

LERSTAD, Université Gaston Berger, Saint-Louis, Sénégal

2022-2023



1 Introduction

2 Principe de la CAH

- Indices de mesure
- Algorithme

3 Interprétation d'un dendrogramme

Introduction

Introduction

- Les techniques de classification sont des méthodes non factorielles qui consistent à regrouper des « objets » qui se ressemblent.
 - Les questions naturelles que l'on se pose :
 - Le nombre de classes est-il connu a priori ?
 - Comment évaluer la ressemblance entre objets et / ou groupes d'objets ?
 - Comment évaluer la pertinence d'une classification ?
- ☞ Dans le cas d'une CAH, le nombre de classes n'est pas connu a priori contrairement à la méthode des centres mobiles.
- ☞ Le but d'une CAH est de trouver une structure (arborescence) permettant la mise en évidence de liens hiérarchiques entre objets et/ou groupes d'objets.

Plan

- 1 Introduction
- 2 Principe de la CAH
 - Indices de mesure
 - Algorithme
- 3 Interprétation d'un dendrogramme

Ressemblance entre variables

- Distance euclidienne (variables quantitatives)

$$d^2(X, Y) = \sum_i (x_i - y_i)^2$$

- Indice de similarité (variables qualitatives)

- Distance du khi-deux
- Indice de Jaccard

$$J(A, B) = \frac{\text{card}(A \cap B)}{\text{card}(A \cup B)}$$

Critère d'agrégation

👉 Le critère d'agrégation mesure la pertinence de la classification.

Plusieurs critères existent comme celui :

- **du saut minimal** entre A et B consiste à regrouper les deux éléments les plus proches de A et B

$$\min \{d(x, y), \text{ avec } x \in A \text{ et } y \in B\}$$

- **du diamètre** entre A et B regroupe les deux éléments les plus éloignés de A et B

$$\max \{d(x, y), \text{ avec } x \in A \text{ et } y \in B\}$$

- **de la moyenne** évalue la distance moyenne entre les éléments de A et de B
- **de Ward** : qui correspond à la maximisation de l'inertie intra (minimise donc l'inertie inter). Dans la pratique c'est le critère le plus utilisé pour effectuer une CAH.

Plan

- 1 Introduction
- 2 Principe de la CAH
 - Indices de mesure
 - Algorithme
- 3 Interprétation d'un dendrogramme

Algorithme

La méthode de CAH est une procédure itérative.

- 1 Début : chaque objet représente un groupe
- 2 Déroulement : regroupement des deux objets les plus proches
- 3 Fin : une classe regroupe tous les objets

Le graphe ainsi obtenu porte le nom de **dendrogramme**.

Exemple


Soit le tableau suivant

Objets	<i>A</i>	<i>B</i>	<i>C</i>	<i>D</i>	<i>E</i>
Valeur 1	2	0	1	1	4
Valeur 2	1	3	1	4	3

Représenter ces points dans un repère.

Utiliser la distance euclidienne ($d(A, B) = \sqrt{(x_A - x_B)^2 + (y_A - y_B)^2}$) et le critère du saut minimal pour effectuer la CAH.

Nuage de points de l'exemple



Algorithme de l'exemple

Début : chaque objet représente un groupe : $\{A\}$, $\{B\}$, $\{C\}$, $\{D\}$ et $\{E\}$.

Déroulement a. Matrice des distances est

	$\{A\}$	$\{B\}$	$\{C\}$	$\{D\}$	$\{E\}$
$\{A\}$	0				
$\{B\}$	2.83	0			
$\{C\}$	1	2.24	0		
$\{D\}$	3.16	1.41	3	0	
$\{E\}$	2.83	4	3.61	3.16	0

On constate que la plus petite distance est $1 = d(\{A\}, \{C\})$, donc on regroupe $\{A\}$ et $\{C\}$, on a $\{A, C\}$.

Algorithme de l'exemple

Déroulement b. Matrice des distances est

	$\{A, C\}$	$\{B\}$	$\{D\}$	$\{E\}$
$\{A, C\}$	0			
$\{B\}$	2.24	0		
$\{D\}$	3	1.41	0	
$\{E\}$	2.83	4	3.16	0

On constate que la plus petite distance est $1.41 = d(\{B\}, \{D\})$, donc dans cette deuxième étape du déroulement on regroupe $\{B\}$ et $\{D\}$ et on obtient $\{B, D\}$.

Algorithme de l'exemple

Déroulement c. Matrice des distances est

	$\{A, C\}$	$\{B, D\}$	$\{E\}$
$\{A, C\}$	0		
$\{B, D\}$	2.24	0	
$\{E\}$	2.83	3.16	0

On constate que la plus petite distance est $2.24 = d(\{A, C\}, \{B, D\})$ donc dans cette troisième étape du déroulement on regroupe les classes $\{A, C\}$ et $\{B, D\}$. On obtient $\{A, C, B, D\}$.

Algorithme de l'exemple

Déroulement d. Matrice des distances est

	$\{A, C, B, D\}$	$\{E\}$
$\{A, C, D, B\}$	0	
$\{E\}$	2.83	0

On obtient une seule classe $\{A, B, C, D, E\}$ à une hauteur de 2.83.

Fin.

Bilan de l'exemple

hauteur $h = 0.00$ $> \{A\}, \{B\}, \{C\}, \{D\}, \{E\}$


hauteur $h = 1.00$ $> \{A, C\}, \{B\}, \{D\}, \{E\}$

hauteur $h = 1.41$ $> \{A, C\}, \{B, D\}, \{E\}$

hauteur $h = 2.24$ $> \{A, B, C, D\}, \{E\}$

hauteur $h = 2.83$ $> \{A, B, C, D, E\}$

Dendrogramme de l'exemple



Le dendrogramme

- 👉 Lorsqu'on se donne une hauteur de coupe de l'arbre, le dendrogramme fournit une classification
- 👉 Plus l'arbre est coupé bas (proche des éléments initiaux), plus la classification est fine
- 👉 Une hauteur de coupe est pertinente si elle se trouve entre deux noeuds dont les hauteurs sont relativement éloignées

Exemple de dendrogramme

Exemple

Considérons l'exemple précédent et on se donne une hauteur de coupe $h = 1.8$. Alors, le dendrogramme fournit la partition suivante : $\{A, C\}$, $\{B, D\}$ et $\{E\}$.

